

Análise Estatística de dados

Inteligência Artificial




AULA 04 – DECOMPOSIÇÃO DE VALOR SINGULAR

Arturo Forner-Cordero
Larissa Driemeier


PROGRAMA DO CURSO

Aula	Data	Conteúdo da Aula
01	27/02	Aula Inaugural
02	05/03	Introdução ao Curso. Noções de Álgebra Linear , Geometria Analítica Parte I
03	12/03	Noções de Álgebra Linear , Geometria Analítica Parte II
04	19/03	Decomposição de valor singular (SVD)
05	26/03	Otimização: derivadas, derivadas parciais (operadores gradiente, Jacobiano, Hessiano e Laplaciano), algoritmos de gradiente
06	02/04	Variáveis independentes e não independentes. Estatística Descritiva e Indutiva. Definições de medidas de dispersão e tendência central.
07	09/04	Probabilidade e Teorema de Bayes
08	16/04	Modelos de probabilidade discretos
09	23/04	Modelos de probabilidade contínuos
10	30/04	Modelo de Markov. Modelo de Markov oculto.

TRANSFORMAÇÃO



$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



Suponha que a transformação $T(x) = Ax$ seja aplicada a um círculo de raio unitário centrado na origem.

AUTOVETORES E AUTOVALORES

$$A = \begin{pmatrix} 3 & 2 \\ 0 & 2 \end{pmatrix} \quad \begin{pmatrix} 3-3 & 2 \\ 0 & 2-3 \end{pmatrix} \begin{pmatrix} u_{1,1} \\ u_{2,1} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 0 & 2 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} u_{1,1} \\ u_{2,1} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\det A = 6, \operatorname{tr} A = 5$$

$$2u_{2,1} = 0 \rightarrow u_{2,1} = 0, \quad u_{1,1} = t$$

$$\lambda^2 - 5\lambda + 6 = 0$$

$$\begin{pmatrix} 3-2 & 2 \\ 0 & 2-2 \end{pmatrix} \begin{pmatrix} u_{1,2} \\ u_{2,2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} u_{1,2} \\ u_{2,2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{aligned} u_{1,2} + 2u_{2,2} &= 0, u_{2,2} = t \\ u_{1,2} &= -2u_{2,2} = -2t \end{aligned}$$

$$\begin{aligned} \lambda_1 &= 3 \\ \lambda_2 &= 2 \end{aligned}$$

autovalores

$$\|u_1\|^2 = t^2 + 0^2 = 1 \\ t = \pm 1$$

$$u_1 = \begin{pmatrix} t \\ 0 \end{pmatrix}$$

$$u_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$\|u_2\|^2 = (-2t)^2 + t^2 = 1 \\ 5t^2 = 1 \rightarrow t = \pm \frac{1}{\sqrt{5}}$$

$$u_2 = \begin{pmatrix} -2t \\ t \end{pmatrix}$$


$$u_2 = \begin{pmatrix} -0,8944 \\ 0,4472 \end{pmatrix}$$

$$T = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



$$\lambda_1 = 3 \quad \lambda_2 = 2$$

$$u_1 = (1, 0) \quad u_2 = (0.89, -0.45)$$

$$\det T = 6$$




Brinque no link: <https://www.geogebra.org/classic/mdvN0HTt>



Veja que um dos autovetores é $(1, 0)$ com autovalor 3.

AUTOVETORES



$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, u_2 = \begin{bmatrix} -0,8944 \\ 0,4472 \end{bmatrix}$$

$$\lambda_1 = 3, \quad \lambda_2 = 2$$

https://github.com/reza-bagheri/SVD_article



Os vetores u_i são os autovetores de A ; os escalares λ_i são chamados autovalores.

EM PYTHON $A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$



```
A = np.array([[3,2],[0,2]])  
# Cálculo de autovalores e autovetores  
lam, u = linalg.eig(A)  
print("autovalores=\n", np.round(lam, 4))  
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=  
[3. 2.]  
autovetores=  
[[ 1. -0.8944]  
 [ 0.  0.4472]]
```


$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$



$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$




PROBLEMA DE AUTOVALORES E MATRIZES SIMÉTRICAS

Duas propriedades importantes surgem quando olhamos para os autovalores e autovetores de uma matriz simétrica $A_{n \times n}$,

- todos n os autovalores de A são reais;
- os n autovetores de A são ortonormais, ou seja, a matriz composta dos autovetores é uma matriz ortogonal.


INTUIÇÃO GEOMÉTRICA PARA MATRIZ 2X2 SIMÉTRICA QUADRADA

Direções de
alongamentos
principais



Eixo secundário


Eixo principal



$$A = \begin{bmatrix} 3 & 1 \\ 1 & 0,8 \end{bmatrix}$$

```
A = np.array([[3, 1],
              [1, 0.8]])
# Cálculo de autovalores e autovetores
lam, u = linalg.eig(A)
print("autovalores=\n", np.round(lam, 4))
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=
[3.3866 0.4134]
autovetores=
[[ 0.9327 -0.3606]
 [ 0.3606 0.9327]]
```



DECOMPOSIÇÃO EM AUTOVALORES

Toda matriz simétrica quadrada pode ser decomposta em,

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{U}^T$$

$$\mathbf{A} = \begin{pmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_n \\ | & | & & | \end{pmatrix} \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \\ & \vdots & \\ - & \mathbf{u}_n^T & - \end{pmatrix}$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

Veja que $\lambda_i \geq 0$ significa matriz definida positiva (ou semidefinida, se pelo possuir qualquer $\lambda_i = 0$)

onde \mathbf{u}_i são n LI autovetores de \mathbf{A} e λ_i são os autovalores de \mathbf{A}

POR EXEMPLO

$$A = \begin{pmatrix} 7 & 3 \\ 3 & -1 \end{pmatrix}$$

$$\det A = -16, \operatorname{tr} A = 6$$

$$\lambda^2 - 6\lambda - 16 = 0$$

```
A = np.array([[7,3],[3,-1]])  
# Cálculo de autovalores e autovetores  
lam, u = linalg.eig(A)  
print("autovalores=\n", np.round(lam, 4))  
print("autovetores=\n", np.round(u, 4))
```

```
autovalores=  
[ 8. -2.]  
autovetores=  
[[ 0.9487 -0.3162]  
 [ 0.3162  0.9487]]
```

$$\lambda_1 = 8$$

$$\lambda_2 = -2$$

$$u_1 = \begin{pmatrix} 0,9487 \\ 0,3162 \end{pmatrix}$$

$$u_2 = \begin{pmatrix} -0,3162 \\ 0,9487 \end{pmatrix}$$

POR EXEMPLO...

$$A = \begin{pmatrix} 7 & 3 \\ 3 & -1 \end{pmatrix}$$

$$\lambda_1 = 8 \rightarrow u_1 = \begin{pmatrix} 0,9487 \\ 0,3162 \end{pmatrix}$$

$$\lambda_2 = -2 \rightarrow u_2 = \begin{pmatrix} -0,3162 \\ 0,9487 \end{pmatrix}$$

$$A = USU^T$$

$$A = \begin{pmatrix} | & | \\ u_1 & u_2 \\ | & | \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & u_1^T & - \\ - & u_2^T & - \end{pmatrix}$$

$$U = \begin{pmatrix} 0,9487 & -0,3162 \\ 0,3162 & 0,9487 \end{pmatrix} \quad S = \begin{pmatrix} 8 & 0 \\ 0 & -2 \end{pmatrix}$$

$$A = \begin{pmatrix} 0,9487 & -0,3162 \\ 0,3162 & 0,9487 \end{pmatrix} \begin{pmatrix} 8 & 0 \\ 0 & -2 \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix}$$

$$A = \begin{pmatrix} 0,9487 \times 8 + (-0,3162) \times 0 & 0,9487 \times 0 + (-0,3162) \times (-2) \\ 0,3162 \times 8 + 0,9487 \times 0 & 0,3162 \times 0 + 0,9487 \times (-2) \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix}$$

$$A = \begin{pmatrix} 7,5896 & 0,6324 \\ 2,5296 & -1,8974 \end{pmatrix} \begin{pmatrix} 0,9487 & 0,3162 \\ -0,3162 & 0,9487 \end{pmatrix} = \begin{pmatrix} 7,0002 & 2,9998 \\ 2,9998 & -1,0002 \end{pmatrix}$$

OUTRO EXEMPLO

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

```
A = np.array([[3, 1],
              [1, 2]])
lam, u = linalg.eig(A)
print("autovalores=\n", np.round(lam, 4))
print("autovetores=\n", np.round(u, 4))
S=np.array([[lam[0], 0],
            [0, lam[1]]])
u1 = np.array(u[:,0])
u2 =np.array(u[:,1])
P=np.array([u1,u2]).T

t = P @ S @ P.T
print("Recupera-se a matriz A\n",t)
```

```
autovalores=
[3.618 1.382]
autovetores=
[[ 0.8507 -0.5257]
 [ 0.5257 0.8507]]
Recupera-se a matriz
A [[3. 1.]
   [1. 2.]
```


$$A = USU^T$$

$$A = \begin{pmatrix} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \end{pmatrix}$$

$$\mathbf{u}_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$

$$\mathbf{u}_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$

$$S = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix}$$

$$U = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix}$$

$$U^T = [\mathbf{u}_1 \quad \mathbf{u}_2]^T = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \end{bmatrix} = \begin{bmatrix} 0.8507 & 0.5257 \\ -0.5257 & 0.8507 \end{bmatrix}$$

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix} \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix} \begin{bmatrix} 0.8507 & 0.5257 \\ -0.5257 & 0.8507 \end{bmatrix}$$

REPARE QUE...

$$S = \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix}$$

$$U = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix}$$

$$A = \boxed{US}U^T$$

$$A = \left(\begin{array}{c|c} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{array} \right) \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \begin{pmatrix} - & \mathbf{u}_1^T & - \\ - & \mathbf{u}_2^T & - \end{pmatrix}$$

$$U = \begin{bmatrix} \boxed{0.8507 \times 3.618 + (-0.5257) \times 0} & \boxed{0.8507 \times 0 + (-0.5257) \times 1.382} \\ \boxed{0.5257 \times 3.618 + 0.8507 \times 0} & \boxed{0.5257 \times 0 + 0.8507 \times 1.382} \end{bmatrix}$$

$$US = \left(\begin{array}{c|c} | & | \\ \lambda_1 \mathbf{u}_1 & \lambda_2 \mathbf{u}_2 \\ | & | \end{array} \right)$$

REPRE QUE...

$$S = \begin{bmatrix} 3.618 & 0 \\ 0 & 1.382 \end{bmatrix}$$

$$U = \begin{bmatrix} 0.8507 & -0.5257 \\ 0.5257 & 0.8507 \end{bmatrix}$$

$$A = U S U^T$$

$$A = \left(\begin{array}{c|c} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{array} \right) \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} \left(\begin{array}{c|c} - & \mathbf{u}_1^T \\ - & \mathbf{u}_2^T \\ - & - \end{array} \right)$$

$$US = \left(\begin{array}{c|c} | & | \\ \lambda_1 \mathbf{u}_1 & \lambda_2 \mathbf{u}_2 \\ | & | \end{array} \right)$$

Similarmente,

$$US^T = \left(\begin{array}{c|c} - & \lambda_1 \mathbf{u}_1^T \\ - & \lambda_2 \mathbf{u}_2^T \\ - & - \end{array} \right)$$

GENERALIZANDO...

$$\begin{aligned}
 \mathbf{S}\mathbf{U}^T &\rightarrow \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} = \\
 &\begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ u_{21} & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ u_{n1} & u_{n2} & \dots & u_{nn} \end{bmatrix} = \\
 &\begin{bmatrix} \lambda_1 u_{11} & \lambda_1 u_{12} & \dots & \lambda_1 u_{1n} \\ \lambda_2 u_{21} & \lambda_2 u_{22} & \dots & \lambda_2 u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_n u_{n1} & \lambda_n u_{n2} & \dots & \lambda_n u_{nn} \end{bmatrix} = \begin{bmatrix} \lambda_1 \mathbf{u}_1^T \\ \lambda_2 \mathbf{u}_2^T \\ \vdots \\ \lambda_n \mathbf{u}_n^T \end{bmatrix}
 \end{aligned}$$

PORTANTO...

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{U}^T$$



$$\mathbf{A} = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \dots \quad \mathbf{u}_n] \begin{bmatrix} \lambda_1 \mathbf{u}_1^T \\ \lambda_2 \mathbf{u}_2^T \\ \vdots \\ \lambda_n \mathbf{u}_n^T \end{bmatrix} =$$




$$\mathbf{A} = \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \dots + \lambda_n \mathbf{u}_n \mathbf{u}_n^T$$

Portanto, a matriz \mathbf{A} pode ser decomposta em n matrizes $\mathbf{u}_i \mathbf{u}_i^T$ $n \times n$ ponderadas de λ_i

VAMOS DEVAGAR PARA ENTENDER...




Suponha um vetor x qualquer, e aplicamos uma matriz A de transformação, simétrica $n \times n$.



<https://towardsdatascience.com/understanding-singular-value-decomposition-and-its-application-in-data-science-388a54be95d>

$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x$$

PROJEÇÃO




Dimensão da
componente de
 x ao longo de u

$$p = \frac{u}{u^T u} u^T x$$


Vetor u
normalizado
dá a direção
de p

$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x + \cdots + \lambda_n u_n u_n^T x$$

$u_i u_i^T x \rightarrow$ Projeta o vetor x na i -ésima direção principal!!!



$$Ax = \lambda_1 u_1 u_1^T x + \lambda_2 u_2 u_2^T x$$



Uma matriz simétrica transforma um vetor alongando-o ou encolhendo-o ao **longo de seus autovetores**.

Além disso, sabemos que as matrizes transformam um autovetor **multiplicando seu comprimento (ou magnitude) pelo autovalor correspondente**.

<https://towardsdatascience.com/understanding-singular-value-decomposition-and-its-application-in-data-science-388a54be95d>

INSIGHT PARA MATRIZ SIMÉTRICA DEFINIDA POSITIVA...

$$A = \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \dots + \lambda_k \mathbf{u}_k \mathbf{u}_k^T + \dots + \lambda_n \mathbf{u}_n \mathbf{u}_n^T$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \dots \geq \lambda_n$$

Quanto maior o autovalor, maior o comprimento do vetor resultante $\lambda_i \mathbf{u}_i \mathbf{u}_i^T$ e mais peso é dado à sua matriz correspondente $\mathbf{u}_i \mathbf{u}_i^T$.




Assim, podemos aproximar nossa matriz simétrica original A somando os termos que têm os maiores autovalores,

$$A \approx \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \dots + \lambda_k \mathbf{u}_k \mathbf{u}_k^T$$

$$A \approx A_1 + A_2 + \dots + A_k$$

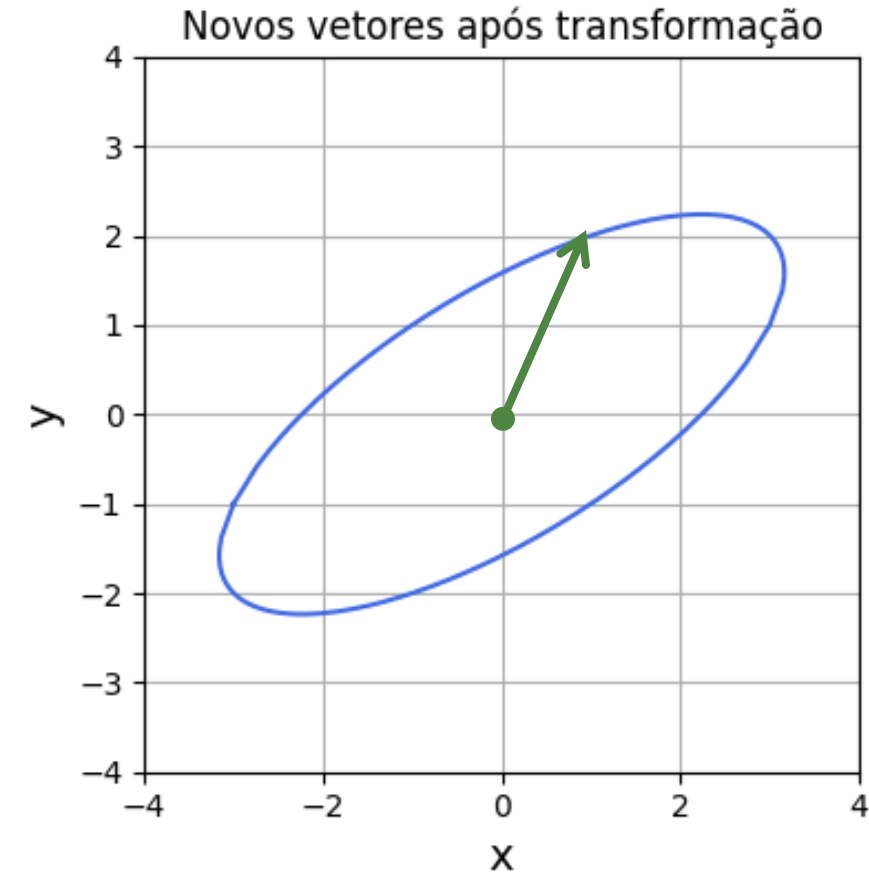
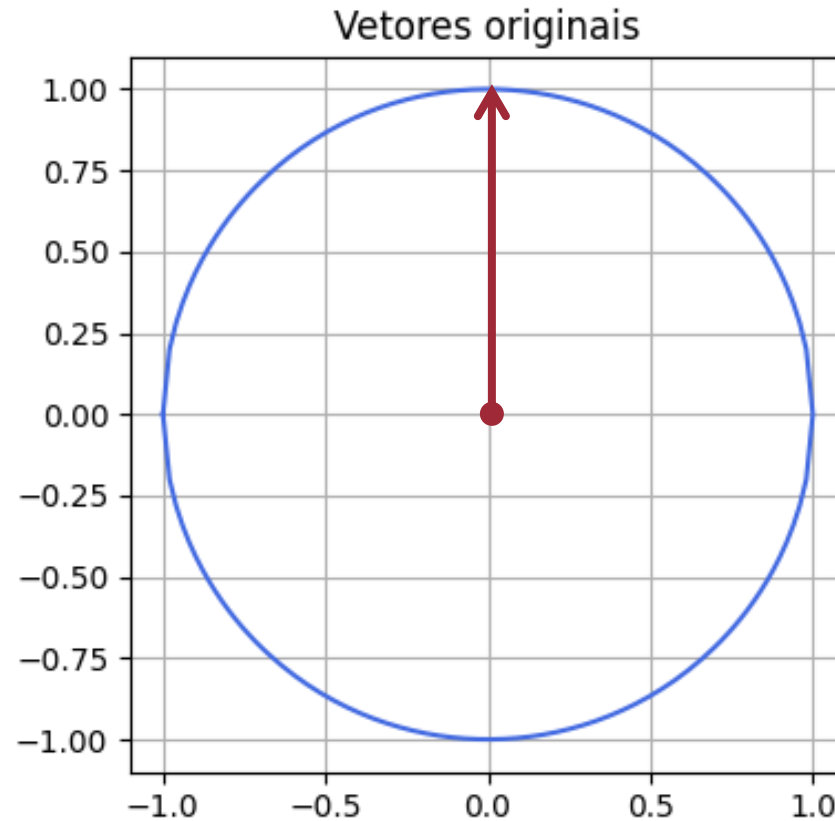
onde A_i é uma matriz de projeção e deve projetar tudo em \mathbf{u}_i .

https://github.com/reza-bagheri/SVD_article



ACHE A PROJEÇÃO A_1

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$



ACHE AS PROJEÇÕES A_1 E A_2

Já usamos essa matriz...

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$

$$u_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$

```
1 # Cálculo de autovalores e autovetores
2 #A = np.array([[3, 2],
3 #              [0, 2]])
4 A = np.array([[3, 1],
5               [1, 2]])
6 lam, u = linalg.eig(A)
7 print("autovalores=", np.round(lam, 4))
8 print("autovetores=", np.round(u, 4))
9
```


```
autovalores= [3.618 1.382]
autovetores= [[ 0.8507 -0.5257]
               [ 0.5257  0.8507]]
```

ACHE A PROJEÇÃO A_1


$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix}, \lambda_1 = 3.618$$


$$u_2 = \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix}, \lambda_2 = 1.382$$



$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$




$$A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$$



$$A_1 = \lambda_1 u_1 u_1^T = 3.61 \begin{bmatrix} 0.8507 \\ 0.5257 \end{bmatrix} \begin{bmatrix} 0.8507 & 0.5257 \end{bmatrix} = \begin{bmatrix} 2.618 & 1.618 \\ 1.618 & 1 \end{bmatrix}$$

$$A_2 = \lambda_2 u_2 u_2^T = 1.382 \begin{bmatrix} -0.5257 \\ 0.8507 \end{bmatrix} \begin{bmatrix} -0.5257 & 0.8507 \end{bmatrix} = \begin{bmatrix} 0.382 & -0.618 \\ -0.618 & 1 \end{bmatrix}$$



ACHE A PROJEÇÃO A_1

$$A = \begin{pmatrix} 5 & 2 \\ 2 & 1 \end{pmatrix}$$

$$u_1 = \begin{bmatrix} 0.9239 \\ 0.3287 \end{bmatrix}, \lambda_1 = 5.8284$$

$$u_2 = \begin{bmatrix} -0.3827 \\ 0.9239 \end{bmatrix}, \lambda_2 = 0.1716$$


$$A_1 = \lambda_1 u_1 u_1^T = \begin{bmatrix} 4.9749 & 2.0607 \\ 2.0606 & 0.8535 \end{bmatrix}$$

```
1 A = np.array([[5, 2],
2               [2,1]])
3 lam, u = linalg.eig(A)
4 print("autovalores=\n", np.round(lam, 4))
5 print("autovetores=\n", np.round(u, 4))
6 S=np.array([[lam[0], 0],
7             [0, lam[1]]])
8 u1 = np.array(u[:,0])
9 u2 =np.array(u[:,1])
10 P=np.array([u1,u2]).T
11
12
13 t = P @ S @ P.T
14 print("Recupera-se a matriz A\n",t)
```


```
autovalores=
[5.8284 0.1716]
autovetores=
[[ 0.9239 -0.3827]
 [ 0.3827  0.9239]]
Recupera-se a matriz A
[[5. 2.]
 [2. 1.]
```


USANDO $A_1 = \lambda_1 u_1 u_1^T + \lambda_2 u_2 u_2^T$

Vetores originais




Novos vetores após transformação




USANDO $A_1 = \lambda_1 u_1 u_1^T$


Vetores originais




Novos vetores após transformação






Vetores originais



Novos vetores após transformação







Se você tiver não uma matriz quadrada
simétrica, não poderá usar o método de
composição por autovalores para
aproximar matrizes...



E a maioria das matrizes que você irá
trabalhar não são nem quadradas e
nem simétricas...



VALORES SINGULARES

Antes de falar em SVD devemos encontrar uma maneira de calcular as direções de alongamento para uma matriz não simétrica. Para isso, definimos “valores singulares”.



MATRIZ $A^T A$

$$(A^T A)^T = A^T (A^T)^T = A^T A$$



A é uma matriz $m \times n$ e não necessariamente simétrica.

A matriz $A^T A$ é positiva semi definida, quadrada ($n \times n$) e simétrica. Portanto, possui autovetores v_i ortogonais e autovalores λ_i não negativos.



Vamos assumir que os vetores v_i estão normalizados, ie,
 $\|v_i\|^2 = v_i^T v_i = 1$



MATRIZ AA^T

$$(AA^T)^T = AA^T$$



A é uma matriz $m \times n$ e não necessariamente simétrica.

A matriz AA^T é positiva semi definida, quadrada ($n \times n$) e simétrica. Portanto, possui autovetores u_i ortogonais e autovalores λ_i não negativos.



Vamos assumir que os vetores u_i estão normalizados, ie,
 $\|u_i\|^2 = u_i^T u_i = 1$

EXEMPLO

$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$





$$A^T A = \begin{bmatrix} 9 & 6 \\ 6 & 8 \end{bmatrix}$$

$$v_1 = \begin{bmatrix} 0.7359 \\ 0.6771 \end{bmatrix}, \lambda_1 = 14.5208$$

$$v_2 = \begin{bmatrix} -0.6771 \\ 0.7359 \end{bmatrix}, \lambda_2 = 2.4792$$

```
ATA = A.T @ A
# Cálculo de autovalores e autovetores
lamv, v = linalg.eig(ATA)
print("A^TA=\n", np.round(ATA, 4))
print("autovalores=\n", np.round(lamv, 4))
print("autovetores=\n", np.round(v, 4))
```

```
A^TA=
[[9 6]
 [6 8]]
autovalores=
[14.5208  2.4792]
autovetores=
[[ 0.7359 -0.6771]
 [ 0.6771  0.7359]]
```



EXEMPLO

$$A = \begin{bmatrix} 3 & 2 \\ 0 & 2 \end{bmatrix}$$





$$AA^T = \begin{bmatrix} 13 & 4 \\ 4 & 4 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} 0.9347 \\ 0.3554 \end{bmatrix}, \lambda_1 = 14.5208$$

$$u_2 = \begin{bmatrix} -0.3554 \\ 0.9347 \end{bmatrix}, \lambda_2 = 2.4792$$

```
AAT = A @ A.T
# Cálculo de autovalores e autovetores
lamu, u = linalg.eig(AAT)
print("AA^T=\n", np.round(AAT, 4))
print("autovalores=\n", np.round(lamu, 4))
print("autovetores=\n", np.round(u, 4))
```

```
AA^T=
[[13  4]
 [ 4  4]]
autovalores=
[14.5208  2.4792]
autovetores=
[[ 0.9347 -0.3554]
 [ 0.3554  0.9347]]
```





VETORES E VALORES SINGULARES

Definição final

VETORES E VALORES SINGULARES

Dada uma matriz $A \in \mathbb{R}^{m \times n}$, as matrizes à esquerda e à direita de A são, respectivamente,

$$\underset{m \times m}{AA^T} \text{ e } \underset{n \times n}{A^T A}.$$

As matrizes AA^T e $A^T A$ têm os mesmos autovalores não nulos.

AA^T e $A^T A$ são matrizes semi definidas positivas, simétricas, reais e quadradas. Portanto, autovalores λ_i de AA^T ou $A^T A$ são reais não negativos, iguais ou distintos.

VALORES SINGULARES DE UMA MATRIZ

Chamamos de **valores singulares** da matriz A , $\lambda_1, \lambda_2, \dots, \lambda_r$, as r raízes quadradas dos autovalores não nulos AA^T ou $A^T A$;

$$\sigma_i = \sqrt{\lambda_i}$$

Os **vetores singulares** u_i à esquerda da matriz A são os autovetores de AA^T , $m \times m$.

Os **vetores singulares** v_i à direita da matriz A são os autovetores de $A^T A$, $n \times n$.

MATRIZES U E V

Os autovetores de AA^T formam as colunas da matriz U e os autovetores de $A^T A$ formam as colunas da matriz V . Como são simétricos, os autovetores podem ser definidos ortonormais, ié, perpendiculares entre si e de comprimento unitário, de forma que:

$$U^T U = I \quad V^T V = I$$

$$U = \begin{pmatrix} | & | & \dots & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_m \\ | & | & & | \end{pmatrix}_{m \times m}$$

$$V = \begin{pmatrix} | & | & \dots & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \\ | & | & & | \end{pmatrix}_{n \times n}$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$$

POR EXEMPLO...

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

```
A = np.array([[3, 2, 2],  
              [2, 3, -2]])  
ATA = A.T @ A  
AAT = A @ A.T
```

$$AA^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix} \quad A^T A = \begin{pmatrix} 13 & 12 & 2 \\ 12 & 13 & -2 \\ 2 & -2 & 8 \end{pmatrix}$$

$$AA^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$$

```
# Cálculo de autovalores e autovetores
lamu, u = linalg.eig(AAT)
print("AA^T=\n", np.round(AAT, 4))
print("autovalores=\n", np.round(lamu, 4))
print("autovetores=\n", np.round(u, 4))
```

$$\lambda_1 = 25 \rightarrow \sigma_1 = 5$$

$$\lambda_2 = 9 \rightarrow \sigma_2 = 3$$

$$U = \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

```
AA^T=
[[17  8]
 [ 8 17]]
autovalores=
[25.  9.]
autovetores=
[[ 0.7071 -0.7071]
 [ 0.7071  0.7071]]
```

$$A^T A = \begin{pmatrix} 13 & 12 & 2 \\ 12 & 13 & -2 \\ 2 & -2 & 8 \end{pmatrix}$$

```
# Cálculo de autovalores e autovetores
lamv, v = linalg.eig(ATA)
print("A^TA=\n", np.round(ATA, 4))
print("autovalores=\n", np.round(lamv, 4))
print("autovetores=\n", np.round(v, 4))
```

$$\lambda_1 = 25 \rightarrow \sigma_1 = 5$$

$$\lambda_2 = 9 \rightarrow \sigma_2 = 3$$

$$\lambda_3 = 0 \rightarrow \sigma_3 = 0$$

$$V = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{18} & 2/3 \\ 1/\sqrt{2} & -1/\sqrt{18} & -2/3 \\ 0 & 4/\sqrt{18} & -1/3 \end{bmatrix}$$

```
A^TA=
[[13 12  2]
 [12 13 -2]
 [ 2 -2  8]]
autovalores=
[25.  0.  9.]
autovetores=
[[-0.7071 -0.6667  0.2357]
 [-0.7071  0.6667 -0.2357]
 [-0.      0.3333  0.9428]]
```




SVD

Definição

SVD

$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$$

$$A_{m \times n} = U_{m \times m} S_{m \times n} V_{n \times n}^T$$



$A_{m \times n}$ é uma matriz de valores reais

$U_{m \times m}$ é uma matriz ortogonal

$S_{m \times n}$ é uma matriz diagonal

$V_{n \times n}^T$ é uma matriz ortogonal

DECOMPOSIÇÃO EM VALORES SINGULARES

O **SVD (Singular Value Decomposition)** é um método para fatorar matrizes:

$$A = USV^T = U \begin{bmatrix} D_{r \times r} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}_{m \times n} V^T$$

onde U e V são as matrizes ortogonais que definimos e S é diagonal.

Os valores da matriz diagonal S são os valores singulares σ_i que acabamos de aprender, e por isso a decomposição recebe este nome.

O número de valores singulares diferentes de zero é igual ao rank da matriz A .

MATRIZ DIAGONAL S

Se A tem r valores singulares não nulos, S é uma matriz da forma:


$$S = \begin{matrix} D_{r \times r} & \begin{pmatrix} \sigma_1 & 0 & 0 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & \ddots & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & \sigma_r & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \end{matrix}$$

Em SVD, os elementos diagonais da matriz S , ié, os valores singulares σ_i , são computados em ordem decrescente $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$


OU SEJA...

$$A = \begin{pmatrix} 3 & 7 \\ 5 & 2 \end{pmatrix} = USV^T = \begin{bmatrix} -0,8506 & -0,52573 \\ -0,52573 & 0,8506 \end{bmatrix} \begin{bmatrix} 8,7134 & 0 \\ 0 & 3,3282 \end{bmatrix} \begin{bmatrix} -0,5945 & -0,8040 \\ 0,8040 & -0,5945 \end{bmatrix}$$


$$A = \begin{pmatrix} 3 & 7 \\ 5 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$




Círculo inicial



Rodado pela matriz V




Escalonado pela matriz S




Rodado pela matriz U


PORTANTO...



Rodado pela matriz V



Escalonado pela matriz S



Rodado pela matriz U

A é uma matriz que pode ser vista como uma transformação linear. Essa transformação pode ser decomposta em três sub-transformações: rotação, escalonamento, rotação. Esses três passos correspondem às três matrizes: U , S e V .

RECUPERANDO A IDEIA DE DECOMPOSIÇÃO

$$A_{m \times n} = U_{m \times m} S_{m \times n} V_{n \times n}^T$$

$$\begin{pmatrix} \mathbf{a}_{11} & \mathbf{a}_{12} & \cdots & \mathbf{a}_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_{m1} & \mathbf{a}_{m2} & \cdots & \mathbf{a}_{mn} \end{pmatrix} = \begin{pmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \\ | & | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \sigma_r & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} - & \mathbf{v}_1^T & - \\ - & \mathbf{v}_2^T & - \\ - & \vdots & - \\ - & \mathbf{v}_n^T & - \end{pmatrix}$$



$$SV^T = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \sigma_r & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_n^T \end{pmatrix} = \begin{pmatrix} \sigma_1 \mathbf{v}_1^T \\ \vdots \\ \sigma_r \mathbf{v}_r^T \\ \vdots \\ \mathbf{0} \end{pmatrix}$$

$$USV^T = (\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_m) \begin{pmatrix} \sigma_1 \mathbf{v}_1^T \\ \vdots \\ \sigma_r \mathbf{v}_r^T \\ \vdots \\ \mathbf{0} \end{pmatrix} = (\mathbf{u}_1)(\sigma_1 \mathbf{v}_1^T) + \cdots + (\mathbf{u}_r)(\sigma_r \mathbf{v}_r^T)$$



$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$

INTERPRETAÇÃO

$$A = \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T$$

Os valores singulares são ordenados por ordem decrescente. Eles correspondem a um novo conjunto de características que são uma combinação linear dos características originais. A primeira característica explica a maior parte da variância dos dados.

VOLTEMOS AO NOSSO EXEMPLO...

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

A matriz \mathbf{A} é 2×3 e possui 2 autovalores não nulos ($r = 2$).

\mathbf{U} tem dimensão 2×2 , \mathbf{S} tem dimensão 2×3 e \mathbf{V}^T tem dimensão 3×3 ,

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} \quad \mathbf{S} = \begin{pmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \quad \mathbf{V}^T = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ 2/3 & -2/3 & -1/3 \end{bmatrix}$$

$$\mathbf{A} = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T$$

$$\mathbf{U} = \begin{bmatrix} \overset{\mathbf{u}_1}{1/\sqrt{2}} & \overset{\mathbf{u}_2}{1/\sqrt{2}} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

$$\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

$$\mathbf{S} = \begin{pmatrix} \overset{\sigma_1}{5} & 0 & 0 \\ 0 & \overset{\sigma_2}{3} & 0 \end{pmatrix}$$

$$\mathbf{V}^T = \begin{bmatrix} \overset{\mathbf{v}_1^T}{1/\sqrt{2}} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ \overset{\mathbf{v}_2^T}{2/3} & -2/3 & -1/3 \end{bmatrix}$$

$$\mathbf{A} = \overset{\sigma_1}{5} \overset{\mathbf{u}_1}{\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}} \overset{\mathbf{v}_1^T}{(1/\sqrt{2} \quad 1/\sqrt{2} \quad 0)} + \overset{\sigma_2}{3} \overset{\mathbf{u}_2}{\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}} \overset{\mathbf{v}_2^T}{(1/\sqrt{18} \quad -1/\sqrt{18} \quad 4/\sqrt{18})}$$


VEJA O EXEMPLO DO NOTEBOOK

$$A = \begin{bmatrix} 4 & 1 & 3 \\ 8 & 7 & -2 \\ 1 & 5 & 4 \end{bmatrix}$$

Os valores
singulares são



$$\begin{aligned}\sigma_1 &= 11,97 \\ \sigma_2 &= 5,57 \\ \sigma_3 &= 3,25\end{aligned}$$

O rank de A_k é 3. Então
 Ax é um elipsóide no
espaço 3-d.



AN

Se usarmos apenas os dois primeiros
valores singulares, o rank de A_k será
2 e A_k multiplicado por x será um
plano.



Se aproximarmos usando o
primeiro valor singular, o rank
de A_k será 1 e A_k multiplicado
por x será uma linha

61

DIFERENÇAS ENTRE SVD E DECOMPOSIÇÃO EM AUTOVALORES

The singular value decomposition (SVD) provides another way to factorize a matrix, into singular vectors and singular values. The SVD allows us to discover some of the same kind of information as the eigendecomposition. However, the SVD is more generally applicable.

— Ian Goodfellow, Yoshua Bengio, Aaron Courville, *Deep Learning (Adaptive Computation and Machine Learning series)*, pags. 44-45, 2016.

- Nem todas as matrizes possuem uma decomposição em autovalores, porém toda matriz tem uma decomposição em valores singulares.

SVD: O TEOREMA FUNDAMENTAL DA ANÁLISE DE DADOS COM MÚLTIPLAS VARIÁVEIS

A decomposição em valor singular é uma técnica fundamental para análise de dados multivariados. Por exemplo, SVD é usado para cálculo de **Pseudo inversa**.

Um objetivo comum da análise de dados multivariada é reduzir a dimensão do problema, escolhendo um pequeno subespaço que captura propriedades importantes dos dados.

Dado que os elementos diagonais da matriz (chamados de valores singulares) no SVD são calculados em ordem decrescente, usa-se SVD para uma **aproximação por matriz de baixo rank**, i.é, redução de dimensão:

- **Análise de componentes principais**



INVERSA E DADOS REAIS

$$Ax = b$$

$$x = A^{-1}b$$

Mas nem todas as matrizes são inversíveis.

PSEUDOINVERSA MOORE-PENROSE

Pseudo inversa de A :

$$A^+$$

de forma que

$$x \approx A^+ b$$

$$Ax = b$$

$$(U, S, V) \leftarrow \text{svd}(A)$$

$$A^+ = VS^+U^T$$

$$A = USV^T$$

$$A^{-1} = (USV^T)^{-1}$$

$$A^{-1} = (V^T)^{-1}S^{-1}U^{-1}$$

onde S^+ é o recíproco $\frac{1}{x_i}$ dos elementos não nulos de S

$$\begin{bmatrix} -3 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 0 \end{bmatrix}^+ = \begin{bmatrix} -1/3 & 0 & 0 \\ 0 & -1/4 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

EXEMPLO

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \quad (\text{singular, inversa não existe})$$

$$A = USV^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

$$A^+ = VS^+U^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1/2 & 0 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$



APROXIMAÇÃO POR MATRIZ DE BAIXO RANK

Eliminação de ruídos, PCA,
compactação de arquivos, etc...



PCA


Qual a ideia?

ANÁLISE DE COMPONENTES PRINCIPAIS

A Análise de Componentes Principais ou PCA (Principal Component Analysis) tem como objetivo **encontrar um meio de condensar a informação contida em várias variáveis originais em um conjunto menor de variáveis estatísticas (componentes) com uma perda mínima de informação.**



Uma questão-chave na análise de dados é descobrir **quais variáveis são responsáveis pela maior parte da variação nos dados** – essas podem não ser as variáveis que você mediu, mas podem ser uma combinação linear das variáveis medidas!




EXEMPLO

$$A = \begin{bmatrix} -1,03 & 0,74 & -0,02 & 0,51 & -1,31 & 0,99 & 0,69 & -0,12 & -0,72 & 1,11 \\ -2,23 & 1,61 & -0,02 & 0,88 & -2,39 & 2,02 & 1,62 & -0,35 & -1,67 & 2,46 \end{bmatrix}$$



SVD:

$$S = \begin{bmatrix} 6,040 & 0 \\ 0 & 0,218 \end{bmatrix}$$

Com um valor singular muito maior que o outro, pode-se assumir que o pequeno valor de σ_2 é devido ao ruído nos dados e que esse valor singular seria idealmente zero.



Nesse caso, a matriz teria uma classificação, o que significa que todos os dados estão na linha definida por u_1 .



FAÇA VOCÊ





$$A = \begin{bmatrix} 2.9 & -1.5 & 0.1 & -1.0 & 2.1 & -4.0 & -2.0 & 2.2 & 0.2 & 2.0 & 1.5 & -2.5 \\ 4.0 & -0.9 & 0.0 & -1.0 & 3.0 & -5.0 & -3.5 & 2.6 & 1.0 & 3.5 & 1.0 & -4.7 \end{bmatrix}$$

COMPACTAÇÃO DE IMAGEM (720, 540)

No Notebook, tente acompanhar a compactação da imagem feita utilizando SVD.

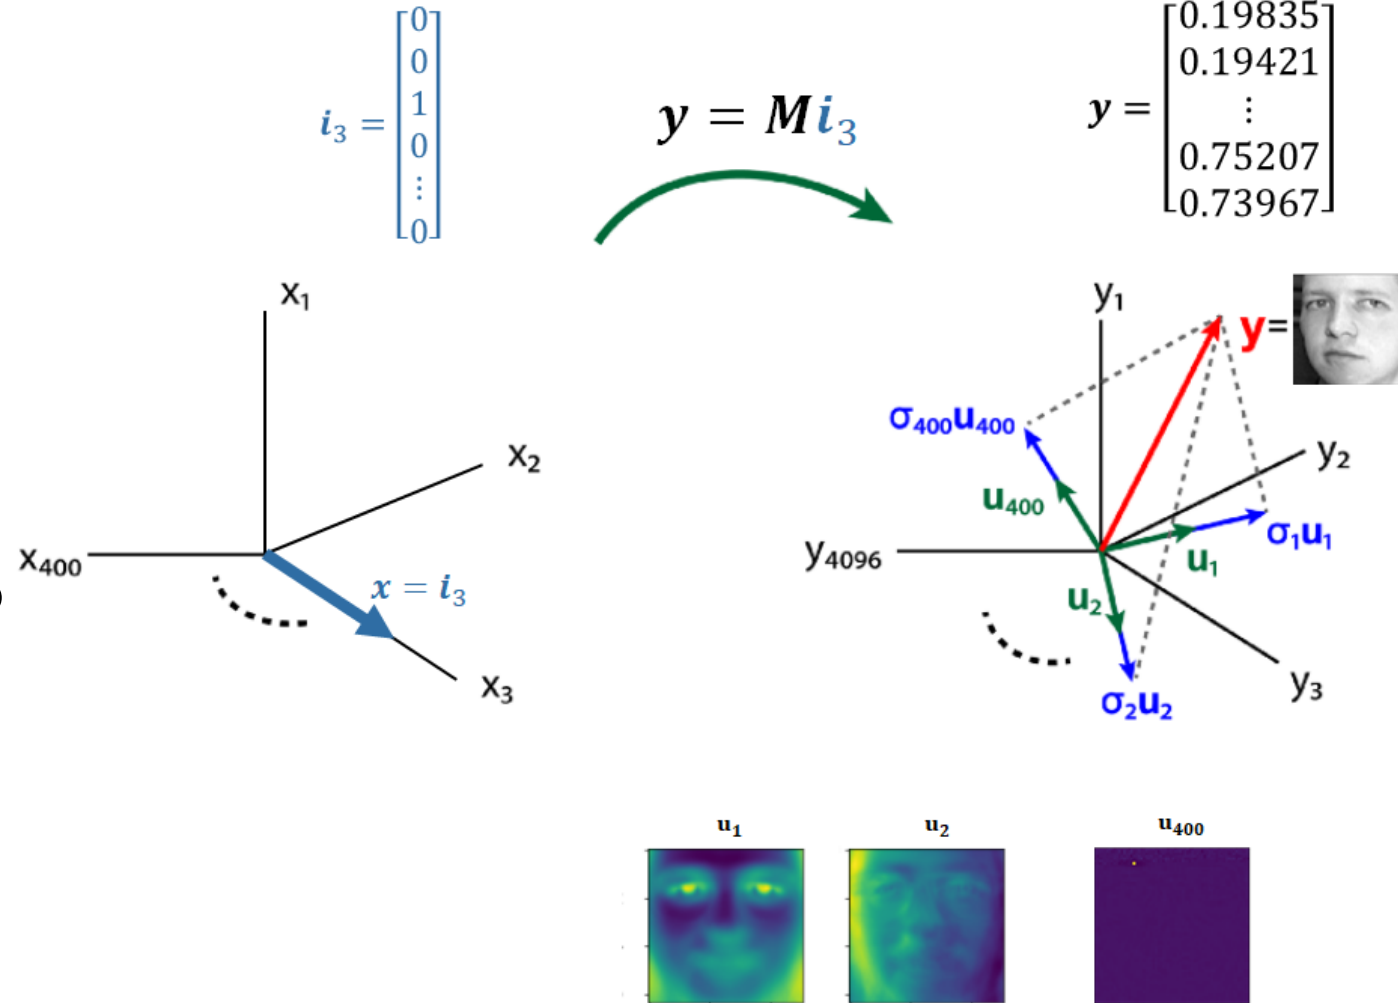
$$A = \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T$$





EIGENFACES

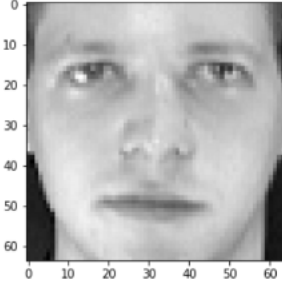
O termo *Eigenfaces* refere-se, basicamente, a um conjunto de características que definem a variação global entre as imagens faciais. O objetivo é **representar uma imagem que retrata o rosto de uma pessoa como uma combinação linear de um conjunto de imagens básicas chamadas de eigenfaces.**




EXEMPLO

Para ilustrar usaremos um dataset de imagens de rosto da biblioteca sklearn.

```
from sklearn.datasets import
fetch_olivetti_faces
data = fetch_olivetti_faces()
imgs = data.images
```



$$= \begin{bmatrix} 0.310 & 0.368 & \dots & 0.306 \\ 0.343 & 0.405 & \dots & 0.314 \\ \vdots & \vdots & \dots & \vdots \\ 0.202 & 0.207 & \dots & 0.157 \end{bmatrix} \rightarrow \mathbf{f}_1 = \begin{bmatrix} 0.310 \\ 0.368 \\ \vdots \\ 0.306 \\ 0.343 \\ 0.405 \\ \vdots \\ 0.314 \\ \vdots \\ 0.202 \\ 0.207 \\ \vdots \\ 0.157 \end{bmatrix}$$



$$\mathbf{M} = [\mathbf{f}_1 \quad \mathbf{f}_2 \quad \mathbf{f}_3 \quad \dots \quad \mathbf{f}_{400}]$$

TEREMOS LIÇÃO DE CASA...

Antes de fazer a lição, estude a aula. Se precisar, veja os textos dos links:

- 1) <https://towardsdatascience.com/understanding-singular-value-decomposition-and-its-application-in-data-science-388a54be95d>
- 2) <https://blogs.sas.com/content/iml/2017/08/30/svd-low-rank-approximation.html>

Se quiser, rode o programa sugerido em Python no segundo link (não é necessário, voltaremos a este tema futuramente).

ENTREGA NO MOODLE ATÉ 24/03, 23:59



1. Com os dados de altura e peso de homens e mulheres, que você pode retirar do link* ,
 - Ache a matriz A ;
 - Ache os valores singulares;
 - Ache U, S, V^T ;
 - Escreva a matriz na forma aproximada, $A_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \dots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$;
 - Discuta suas conclusões, analisando a matriz A_k .
2. Use uma foto da sua face de dimensão 64 x64, e tente recuperá-la utilizando os valores singulares da matriz `M`. Discuta o resultado.

*<https://www.kaggle.com/datasets/mustafaali96/weight-height>



E AGORA...????

Revejam o material disponibilizado em aula.
NÃO PERCAM A PRÓXIMA AULA.
Até a próxima semana!!!